

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

Khoa Công nghệ Thông tin 2

ĐỀ CƯƠNG ĐỀ TÀI MÔN HỌC

Distributed Database Project Proposal

Họ và tên	Trần Hữu Trung
MSSV	N23DCCN200
Lớp	D23CQCN03-N
Môn học	Cơ sở dữ liệu phân tán
Giảng viên	Lê Hà Thanh
Mã & Loại đề tài	#140 – Hybrid Document-Graph Store

1. Thông Tin Dự Án (Project Identity)

Thành viên / Team Members: Trần Hữu Trung (N23DCCN200)

Tên đề tài / Project Title: Hybrid Document-Graph Store: Xây dựng Cơ sở Tri thức Y tế Phân tán kết hợp BM25F Full-Text Search và METIS Graph Partitioning

2. Mục Tiêu & Phát Biểu Bài Toán (Objective & Problem Statement)

Lý do thực hiện ("The Why")

Trong lĩnh vực y tế, một câu hỏi truy vấn thực tế như "Tìm tất cả bệnh nhân có triệu chứng đau ngực và liên quan đến các bệnh tim mạch" đòi hỏi phải kết hợp hai loại dữ liệu hoàn toàn khác nhau: (1) dữ liệu văn bản phi cấu trúc từ hồ sơ bệnh nhân và (2) quan hệ ngữ nghĩa phức tạp trong đồ thị tương quan bệnh. Các hệ thống đơn mô hình (chỉ document store hoặc chỉ graph database) không thể trả lời câu hỏi này một cách hiệu quả.

Đề tài này giải quyết thách thức: làm thế nào để thiết kế một hệ thống phân tán lai (hybrid) kết hợp Document Store và Graph Store, tối ưu hóa chi phí Join giữa hai engine, và đảm bảo kết quả truy vấn phản ánh cả độ liên quan ngữ nghĩa (BM25F score) lẫn khoảng cách đồ thị (graph distance)?

Thuật toán / giao thức cốt lõi (Core Logic)

- BM25F (Best Match 25 with Field-weighted scoring): Thuật toán xếp hạng tài liệu đa trường, mở rộng từ BM25 chuẩn Okapi. Trong hệ thống này, MultifieldParser với OrGroup được sử dụng trên 5 trường: chief_complaint, symptoms, medical_history, initial_diagnosis, full_text với trọng số bằng nhau.

- METIS Recursive Bisection: Thuật toán phân vùng đồ thị đa cấp (multilevel graph partitioning) của Karypis & Kumar (1998), phân chia đồ thị bệnh tương quan thành 4 phân vùng theo chiến lược Edge-Cut, tối thiểu hóa số cạnh bị cắt ngang các phân vùng.
- Hybrid Scoring Formula: Kết hợp điểm BM25F và graph_importance theo công thức: $score = w_1 \times \text{normalize}(\text{BM25F_score}) + w_2 \times \text{graph_importance}$, với graph_importance giảm dần theo hop distance: 0-hop=1.0, 1-hop=0.8, 2-hop=0.5, 3-hop=0.2.

3. Đặc Tả Bộ Dữ Liệu (Dataset Specification)

Bộ dữ liệu 1: Patient_Symptoms (Document Store)

Nguồn (Source): Dữ liệu tổng hợp tự sinh (synthetic data generator) – không dùng dữ liệu bệnh nhân thực vì lý do bảo mật y tế

Kích thước (Size): 500 hồ sơ bệnh nhân – ~2.5 MB JSON

Schema (Patient_Symptoms):

Trường (Field)	Kiểu dữ liệu	Mô tả	Lập chỉ mục
patient_id	String (ID)	Mã bệnh nhân duy nhất	Không
age	Integer	Tuổi bệnh nhân (18–85)	Stored
gender	String	Giới tính (Male/Female)	Stored
chief_complaint	Text	Triệu chứng chính khi nhập viện	BM25F
symptoms	Text	Danh sách triệu chứng mở rộng	BM25F
medical_history	Text	Tiền sử bệnh án	BM25F
current_medications	Text	Thuốc đang dùng (lưu trữ, không index BM25F)	Stored
initial_diagnosis	Text	Chẩn đoán bác sĩ	BM25F
severity	Integer (1-5)	Mức độ nghiêm trọng (1-5)	Filter
department	Keyword	Khoa điều trị (10 chuyên khoa)	Filter
admission_date	String (Date)	Ngày nhập viện	Stored

Bộ dữ liệu 2: Disease_Correlations (Graph Store)

Nguồn (Source): Dữ liệu tổng hợp dựa trên kiến thức y học tổng quát

Kích thước (Size): 200 nút (nodes), ~800 cạnh có trọng số (weighted edges) – ~0.8 MB JSON

Schema (Disease_Correlations):

- Node types: Disease (bệnh, ~51 nút), Symptom (triệu chứng, ~70 nút), Medical Field (lĩnh vực y tế, 10 nút), Medication (thuốc, ~40 nút).
- Edge attributes: correlation_weight (0.0–1.0), relationship_type (disease_to_symptom / disease_to_disease / symptom_to_symptom / disease_to_field / disease_to_drug).

Chiến lược phân mảnh (Fragmentation Strategy)

- Dữ liệu bệnh nhân được phân bố theo department (10 khoa). Whoosh index hiện tại là một index tập trung duy nhất; DocumentIndexManager hỗ trợ tạo index riêng theo partition cho triển khai phân tán trong tương lai.
- Phân mảnh đồ thị (Graph Partitioning) cho Graph Store: METIS Edge-Cut chia đồ thị thành 4 phân vùng cân bằng. Mục tiêu: Edge-Cut Ratio (ECR) < 0.25 và Balance Factor ≤ 1.2 .

4. Kiến Trúc Hệ Thống (System Architecture)

Số nodes mô phỏng (Nodes): 4 phân vùng logic (METIS partitions) mô phỏng 4 site phân tán; tối thiểu 2 site active đồng thời

Tầng giao tiếp (Communication Layer): HTTP/REST API qua Flask – các engine giao tiếp nội bộ qua function call (in-process); cross-partition query được log để tính Communication Cost

Lưu trữ (Storage): JSON files (raw data) + Whoosh Index (inverted index on disk) + METIS partition file (partitions.txt)

Luồng xử lý truy vấn lại:

- Bước 1 – Nhận request: API Layer nhận POST /api/query với tham số query_text, target_field, traversal_algorithm, text_weight, graph_weight.
- Bước 2 – Document Search: Document Engine thực hiện BM25F search trên Whoosh index, trả về top-k kết quả có điểm số.
- Bước 3 – Graph Traversal: Graph Engine thực hiện BFS/DFS/Dijkstra từ target_field node, tính graph_importance cho mỗi bệnh liên quan.
- Bước 4 – Hybrid Join: Hybrid Engine join hai tập kết quả theo disease name (semantic key), tính combined_score, phân tích chi phí join.
- Bước 5 – Trả kết quả: Sắp xếp theo combined_score giảm dần, trả JSON về giao diện web.

5. Công Nghệ & Kế Hoạch Triển Khai (Tech Stack & Implementation Plan)

Ngôn ngữ lập trình (Programming Language): Python 3.9+

Triển khai (Deployment): Localhost – chạy trực tiếp bằng python run.py; hỗ trợ thêm standalone HTML (không cần cài đặt)

Thư viện & Framework (Libraries / Frameworks):

Thư viện / Framework	Mục đích sử dụng
Whoosh 2.7+	BM25F full-text indexing và search engine (pure Python, không cần Java)
NetworkX 3.x	Graph data structure, BFS/DFS/Dijkstra traversal, centrality analysis
METIS (python-metis)	Multilevel graph partitioning (Edge-Cut); fallback hash partitioning nếu binary không có
Flask 3.x + CORS	REST API backend, routing, JSON response
D3.js v7	Interactive graph visualization trên trình duyệt
Pandas	Phân tích chi phí join và thống kê

6. Chỉ Số Đánh Giá & Phân Tích (Success Metrics & Analysis)

Chỉ số định lượng (Quantitative Metrics):

Chỉ số	Mô tả đo lường	Mục tiêu
Edge-Cut Ratio (ECR)	$ E_cut / E_total $ – tỉ lệ cạnh bị cắt ngang partition	$ECR < 0.25$
Balance Factor	$\max(P_i) / \text{avg}(P_j)$ – độ cân bằng kích thước các partition	≤ 1.2
BM25F Precision@10	Tỉ lệ kết quả liên quan trong top-10 với query mẫu	≥ 0.7
Join Cost (ms)	Thời gian thực thi 3 chiến lược join với cùng query	Hash Join tốt nhất khi $k > 50$
Communication Cost	Số cross-partition edge accesses $\times$ network_latency	Tối thiểu hóa
Query Latency (ms)	Thời gian phản hồi end-to-end từ lúc nhận request đến trả kết quả	$< 500\text{ms}$ với 500 docs

Kịch bản thất bại ("Failure Scenario") – bắt buộc thể hiện trong video demo:

- Kịch bản 1 – METIS mất cân bằng: "Khi số nút Medical Field tập trung vào 1-2 partition $\rightarrow$ Edge-Cut Ratio tăng vượt ngưỡng 0.25 $\rightarrow$ hệ thống log cảnh báo và hiển thị partition imbalance trong trang Analysis."
- Kịch bản 2 – Graph distance vượt ngưỡng: "Khi $\text{graph_distance} > 3 \rightarrow \text{graph_importance}$ tự động gán = 0.1 (fallback minimum), thay vì 0.0, để đảm bảo kết quả vẫn hữu ích dù node ở xa lĩnh vực mục tiêu."

- Kịch bản 3 – So sánh 3 chiến lược Join: "Filter-After-Join chậm hơn Hash Join 3–5× khi $k > 50$ kết quả; Index Nested-Loop tối ưu khi $k < 20$."
- Kịch bản 4 – METIS binary không khả dụng: "Hệ thống tự động fallback sang hash-based partitioning, vẫn hoạt động đúng nhưng ECR tăng lên ~0.40."

7. Các Mốc Dự Án (Project Milestones)

Mốc	Thời gian	Nội dung công việc	Đầu ra (Deliverable)
Milestone 1	Tuần 1–3	Nghiên cứu lý thuyết Özsü & Valduriez; thiết kế kiến trúc hệ thống; viết đề cương; xây dựng data generator tạo 500 bệnh nhân và đồ thị 200 nút	Đề cương nộp (tuần 3); JSON dataset
Milestone 2	Tuần 4–6	Cài đặt Document Engine (Whoosh BM25F schema, indexing, search); cài đặt Graph Engine (NetworkX graph construction, METIS partitioning); tích hợp 2 engine	Document Engine + Graph Engine hoạt động độc lập
Milestone 3	Tuần 7–9	Cài đặt Hybrid Engine (3 chiến lược join, combined scoring); phát triển Flask REST API; xây dựng giao diện web (3 trang: Query, Graph, Analysis)	Hệ thống hoàn chỉnh chạy được tại localhost:5000
Milestone 4	Tuần 10–12	Kiểm thử failure scenarios; benchmark 3 chiến lược join; hoàn thiện tài liệu (Design Doc, Analysis Report); quay video demo 3–5 phút; nộp toàn bộ	Tất cả deliverable + video demo + repository GitHub

Sinh viên thực hiện

Trần Hữu Trung

N23DCCN200 – D23CQCN03-N